UNIVERSIDAD DEL VALLE DE GUATEMALA

DATA SCIENCE - 40

Erick Marroquin



Laboratorio 10 Visualización interactiva
Informe final

Ihan Marroquin 23108

Diego Patzan 23525

Milton Polanco 23471

GUATEMALA, 24 de octubre del 2026

Repositorio: github.com/UVG-Tareas-y-proyectos/lab10_ds/tree/main

Tema y alcance del tablero

El tablero permite explorar los ingresos registrados de turistas y excursionistas a Guatemala, identificar mercados y puntos de acceso y consultar el error de modelos evaluados anteriormente. La versión final contiene ocho visualizaciones interactivas. La serie temporal está enlazada con el desglose mensual por vía; la consulta incluye filtros de años, meses, nivel de detalle y selección de gráficas.

Está dirigido a directivos y responsables de planificación turística. Las preguntas de gestión orientan la navegación; las unidades, leyendas y notas permiten leer los resultados sin formación estadística. Los valores observados se distinguen de las estimaciones y las limitaciones acompañan las vistas que afectan.

Preguntas de gestión

- ¿Cómo cambió el flujo de turistas y excursionistas y qué meses concentraron mayores ingresos?
- ¿Cómo se distribuye el mes seleccionado entre las vías aérea, marítima y terrestre?
- ¿Qué países de residencia aportan mayor volumen dentro de una región seleccionada?
- ¿Cómo cambia el ingreso de visitantes según la región de residencia?
- ¿Qué puntos de ingreso concentran el flujo y cómo cambia el ranking por vía?
- ¿Qué meses superaron la referencia estacional entre 2009 y 2019?
- ¿Qué error registran tres modelos simples y cómo difieren las estimaciones LSTM de las observaciones?
- ¿Qué periodos tienen cobertura comparable y qué cambios de fuente limitan las conclusiones?

Alcance de la versión final

Se incluyen ocho gráficas: evolución temporal, vías del mes seleccionado, evolución regional, ranking de países, ranking de fronteras, índice estacional, error de modelos y observaciones frente a estimaciones LSTM. Las tarjetas, los controles y la tabla de métricas son complementarios y no se cuentan como visualizaciones.

Se reutilizan resultados de los laboratorios 1 y 2, sin entrenar modelos nuevos. La consulta histórica permite agregar por mes, trimestre o año y acotar los meses incluidos. Las métricas y el índice estacional conservan sus periodos fijos. El tablero no identifica causas, no estima personas únicas y no genera pronósticos futuros.

Datos empleados

La fuente principal es Base_Migracion_2009-2026jun.xlsx, hoja Datos, con 161,036 registros y 13 variables. Se conservan Turista y Excursionista y se excluyen Viajero y la categoría independiente Cruceristas. La cantidad Viajero representa ingresos registrados; una misma persona puede aparecer en varios ingresos.

El filtro conserva 137,642 registros. La serie contiene 210 meses y suma 46,711,912.89 ingresos entre enero de 2009 y junio de 2026. El 59.1 % corresponde a la vía terrestre y diciembre de 2019 registra el máximo mensual. Las sumas por país, región, frontera y vía reproducen el total mensual del avance.

Preparación y limitaciones de los datos

El proceso conserva los originales en data/raw y genera agregados en data/processed mediante src/preparar_datos.py. Se valida continuidad de meses, cantidades no negativas y conservación del total.

El archivo auditoria.json registra conteos y huellas SHA256. El índice estacional usa años completos de 2009 a 2019. Las métricas de modelos se copian de resultados guardados; no se ajustan modelos.

- La base fue preparada para fines académicos y no constituye una publicación oficial.
- Las fuentes cambian entre 2009-2020, 2021-2022 y 2023-2026.
- Desde 2023 cambian la metodología y el detalle disponible por país.
- La vía marítima pierde detalle desde 2017.
- Los años 2020 y 2021 son atípicos; 2026 contiene solamente enero-junio.
- Los valores decimales corresponden a expansiones de encuesta.

Diseño visual

Se conserva la paleta del avance. Azul profundo identifica observaciones; turquesa y verde gris apoyan comparaciones; ocre señala la referencia; coral distingue estimaciones y periodos atípicos. El gris y un violeta auxiliar separan categorías regionales. Fondo claro y texto oscuro sostienen la legibilidad. La predicción también usa línea discontinua y las leyendas explican cada serie, de modo que el color no sea la única señal.

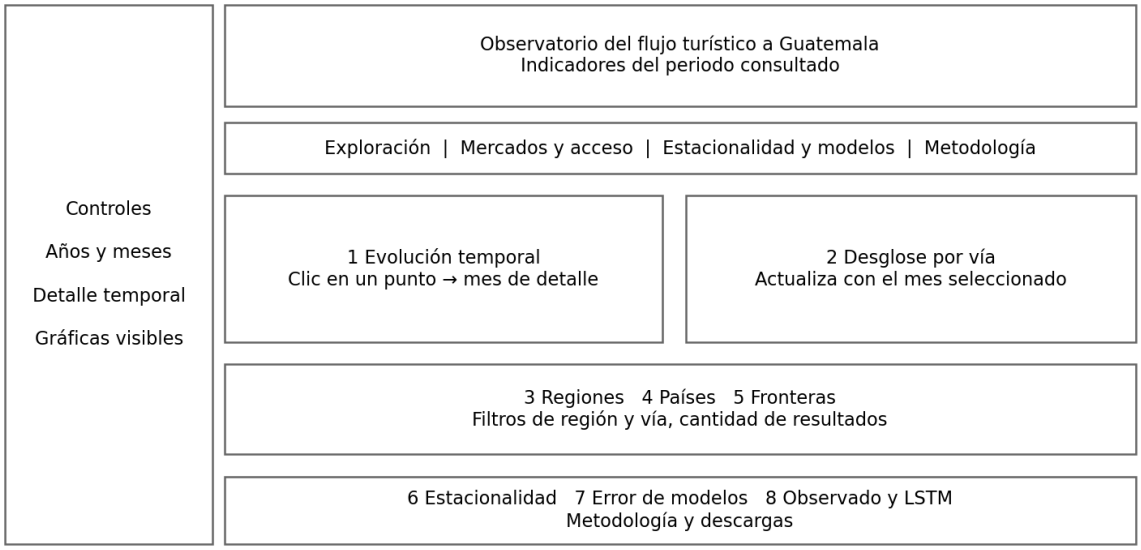


Paleta utilizada en el tablero.

La interfaz usa la fuente sans serif de Streamlit para favorecer la lectura en pantalla. La jerarquía distingue título, secciones y notas; las gráficas muestran unidades y valores exactos al pasar el cursor. El selector de mes ofrece una alternativa al clic sobre un punto. Los controles visibles permiten corregir la consulta sin perder el contexto.

Bosquejo de interfaz y navegación

La barra lateral permite seleccionar años, meses, escala temporal y gráficas visibles. Exploración contiene los indicadores, la serie y su desglose enlazado. Mercados y acceso reúne regiones, países y fronteras. Estacionalidad y modelos presenta referencias históricas y evaluación predictiva. Metodología contiene definiciones, advertencias y descargas. Cada vista incluye la pregunta de gestión y su alcance.



Bosquejo de navegación y de las ocho visualizaciones de la versión final.

Herramienta seleccionada

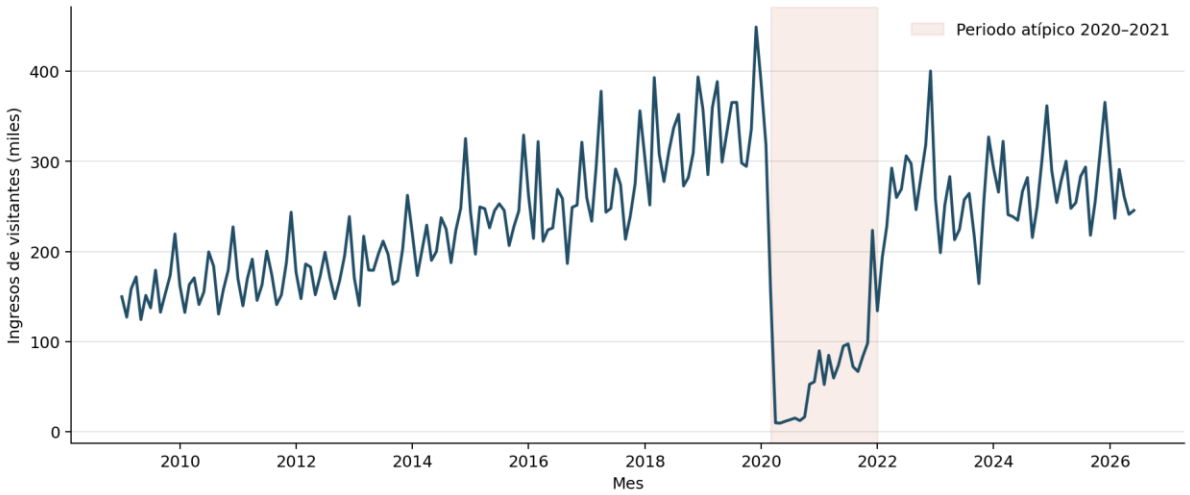
Streamlit permite integrar controles, mensajes y navegación con Python, el lenguaje empleado en los laboratorios anteriores. Plotly aporta zoom, leyendas interactivas, valores emergentes y selección de puntos. El evento de selección actualiza el mes consultado y las barras por vía. Pandas realiza agregaciones explícitas sin volver a ajustar modelos. Son herramientas gratuitas y de código abierto adecuadas para un tablero académico reproducible.

Desde la raíz se instalan requirements.txt, se ejecuta python -m src.preparar_datos y se abre python -m streamlit run app.py. Si faltan los procesados, la primera apertura los genera. El proyecto adopta src, notebooks, data/raw y data/processed según la referencia del curso. app.py mantiene el comando del avance; las fuentes y resultados guardados permiten ejecutarlo sin servicios externos.

Ocho visualizaciones funcionales

1 Evolución del ingreso de visitantes

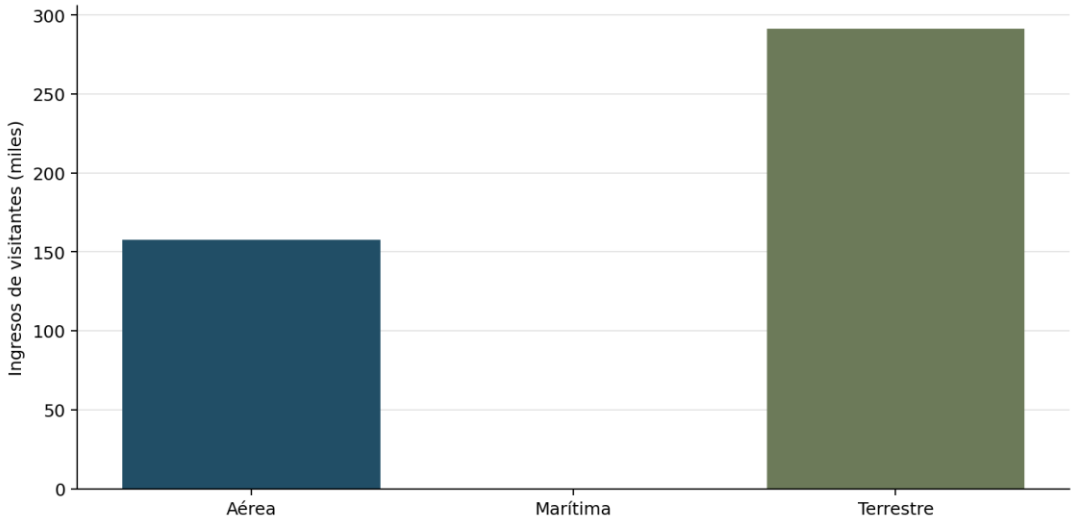
La línea permite seguir cambios en el tiempo, una tarea adecuada para una serie ordenada. El usuario filtra años y meses, cambia entre mes, trimestre y año, usa zoom y selecciona un punto. La selección actualiza la gráfica de vías. Un punto trimestral o anual abre su último mes disponible; el selector permite consultar otros meses. Los agregados suman solamente los meses incluidos en el filtro.



Serie mensual observada. El sombreado identifica el periodo atípico 2020 y 2021.

2 Vía de ingreso del mes seleccionado

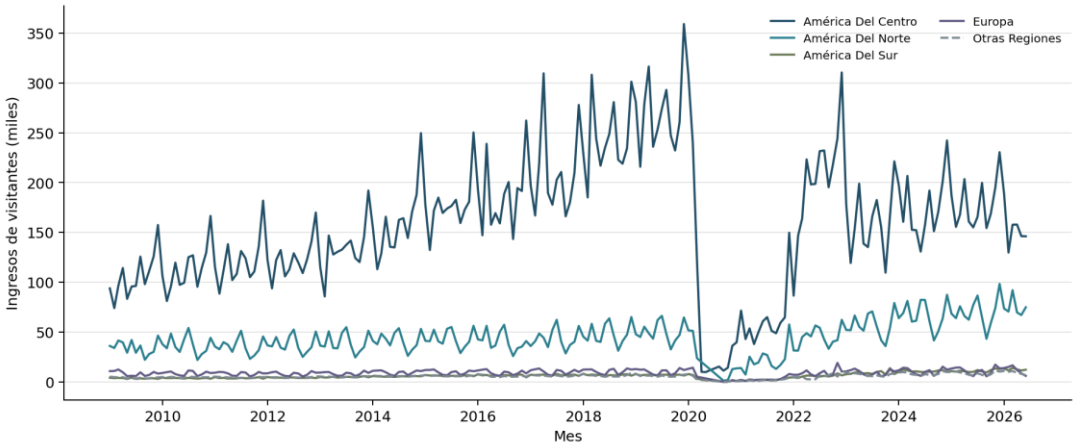
Las barras comparan tres cantidades con una base común, lo que facilita distinguir diferencias entre vías. Reciben el mes seleccionado en la serie y permiten examinar valores exactos o ampliar una zona. El selector de mes conserva una alternativa accesible. Al cambiar el periodo, una selección que queda fuera del filtro se reinicia al último mes disponible. Esta vista ayuda a revisar capacidad de acceso, con reservas sobre el registro marítimo desde 2017.



Ejemplo del desglose enlazado para diciembre de 2019.

3 Evolución por región de residencia

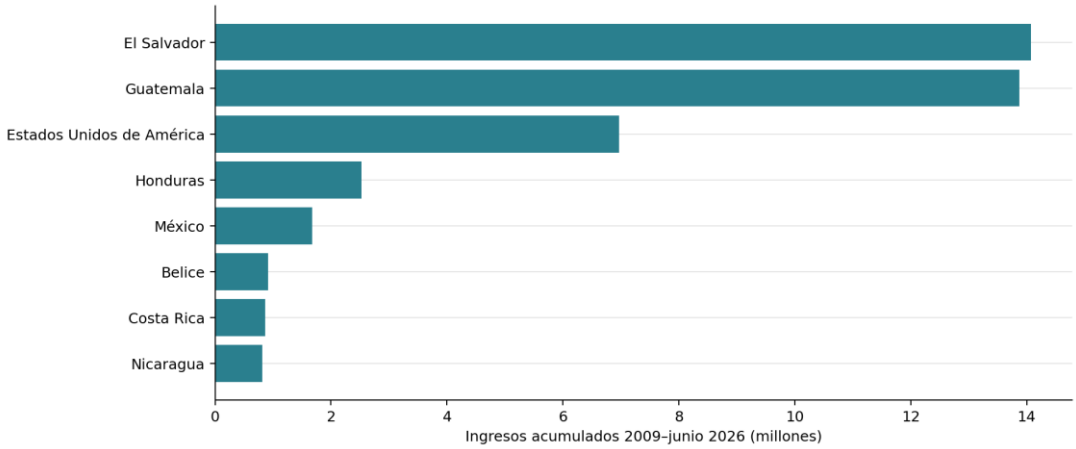
Las líneas muestran la trayectoria de las cuatro regiones con mayor flujo del periodo y agrupan el resto en Otras regiones para evitar una leyenda saturada. El usuario cambia años, meses y nivel temporal y oculta series con la leyenda. El selector regional restringe el ranking de países. Esta vista ayuda a revisar diferencias entre mercados; las categorías se conservan como aparecen en la fuente, sin atribuir causas.



Evolución regional con cuatro categorías principales y el resto agrupado.

4 Países de residencia con mayor flujo

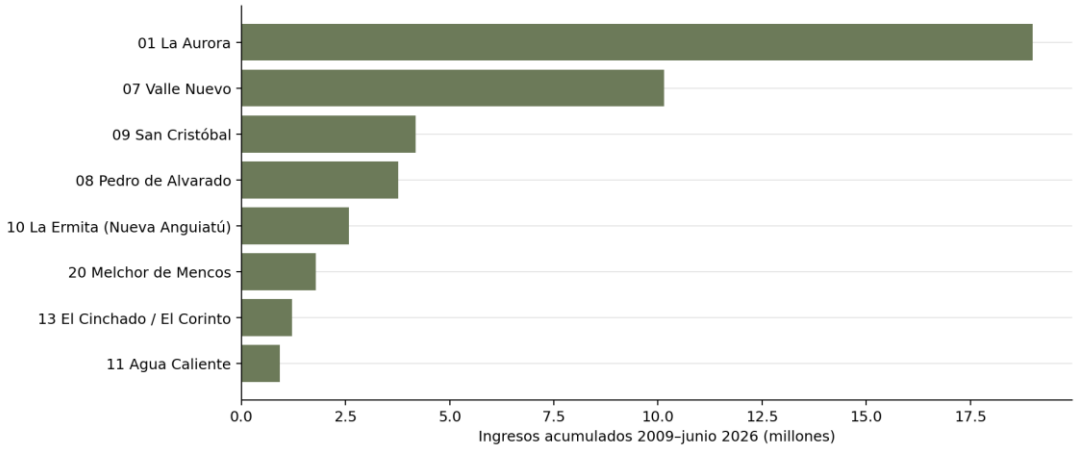
Las barras horizontales facilitan comparar cantidades y leer nombres largos. El ranking responde a los años, los meses, la región y la cantidad de países seleccionada entre 3 y 20. Los valores emergentes muestran cantidades exactas. Su utilidad es localizar mercados con mayor volumen, considerando el cambio de detalle por país desde 2023.



Ranking ilustrativo de países para toda la cobertura disponible.

5 Puntos de ingreso con mayor flujo

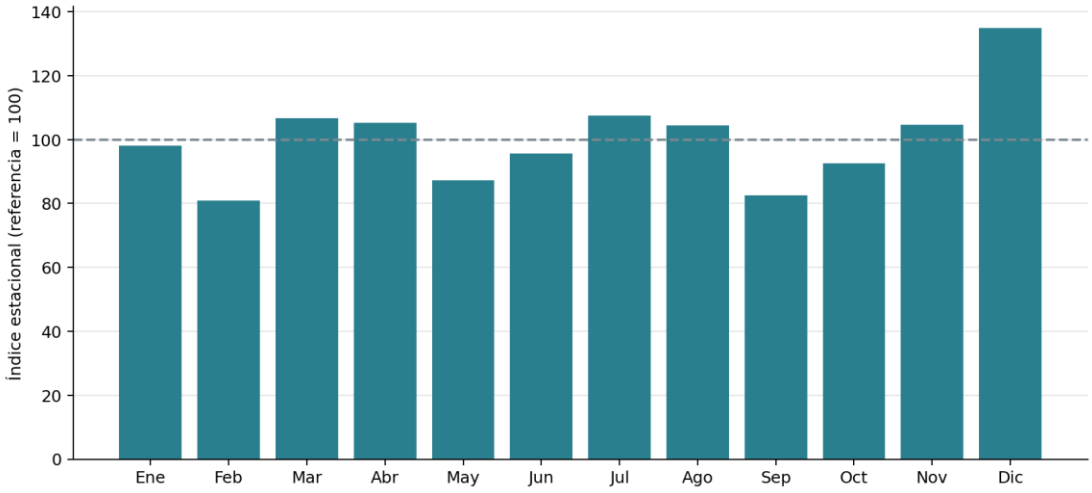
El ranking de barras horizontales permite comparar puntos de acceso con etiquetas legibles. El usuario filtra la vía, los años y los meses y cambia la cantidad de fronteras mostradas. Si no hay registros se presenta un mensaje explícito. Esta vista permite revisar concentración de ingresos, sin equiparar falta de detalle o ceros registrados con ausencia de actividad.



Ranking ilustrativo de fronteras con toda la cobertura disponible.

6 Índice estacional de referencia

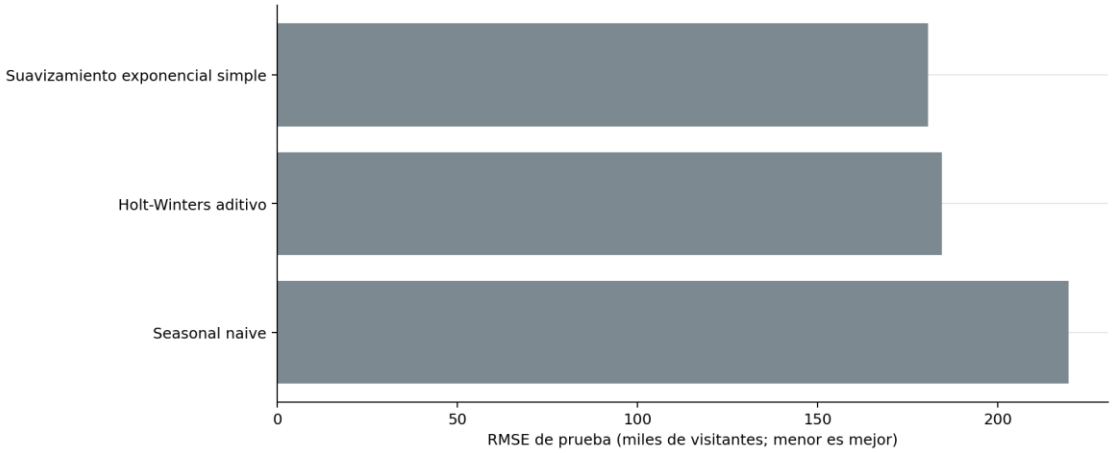
Las barras permiten comparar los doce meses con la línea de referencia 100. Para cada año completo de 2009 a 2019 se divide cada mes por el promedio de ese año y se promedian las razones entre años. Diciembre alcanza 134.9, aproximadamente 34.9 % sobre la referencia. El usuario examina valores y amplía la gráfica. Este patrón orienta escenarios de carga, sin asegurar que se repita en años futuros.



Índice estacional reproducido con años completos de 2009 a 2019.

7 Error de modelos del Laboratorio 1

Las barras horizontales comparan el error con nombres de modelos legibles. La vista inicia con tres modelos simples: suavizamiento exponencial simple, Holt-Winters aditivo y Seasonal naive. Permite elegir modelos adicionales y alternar RMSE y MAE. Sus RMSE son 180,598.23, 184,529.72 y 219,663.87 visitantes, respectivamente. Entre estos tres, SES registra el menor RMSE. Los resultados corresponden a la división cronológica 70/30 del Lab 1: 147 meses de entrenamiento y 63 de prueba, de abril de 2021 a junio de 2026.

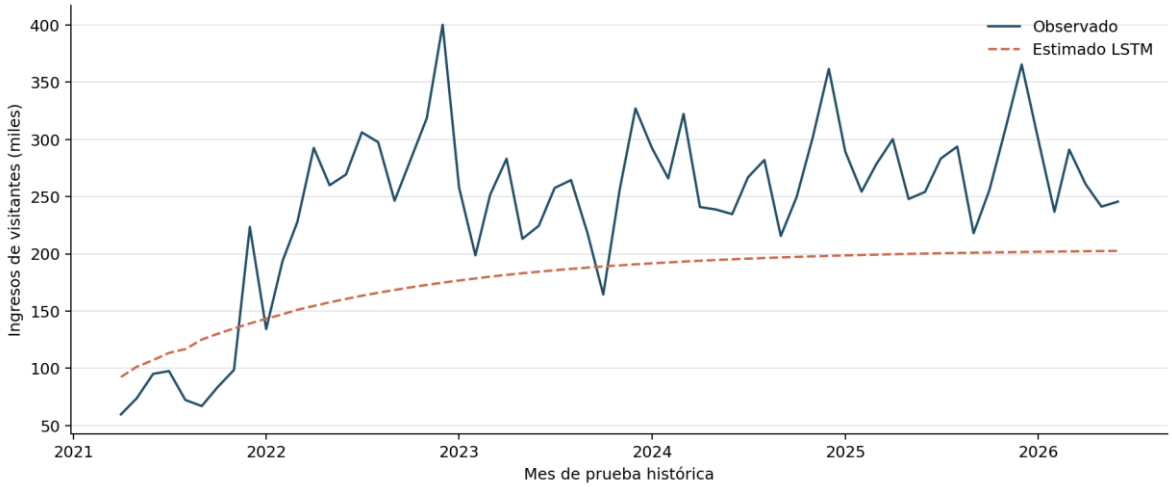


RMSE de tres modelos simples reutilizados del Laboratorio 1; menor error es mejor.

Las métricas finales provienen de la exportación original del Lab 1 y difieren de las transcritas en el avance. Se conservan ambos archivos y se documenta la procedencia en codebook.md. La etiqueta Prophet - respaldo aditivo corresponde a un modelo alternativo usado cuando la biblioteca Prophet no estaba disponible. MAE es el error absoluto medio y RMSE penaliza más los errores grandes; ambos se expresan en visitantes. sMAPE expresa un error porcentual simétrico.

8 Observaciones y estimaciones LSTM del Laboratorio 2

Dos líneas sobre el mismo eje temporal permiten localizar divergencias entre observación y estimación histórica. Azul sólido identifica valores observados y coral discontinuo las estimaciones. El usuario elige la serie total o América del Norte, consulta valores y usa zoom. Para la serie total, MAE es 74,090, RMSE 85,805 y sMAPE 34.4 %. Estas métricas se presentan aparte: no se asegura que el protocolo de ambos laboratorios sea equivalente. No se incluyen meses futuros ni intervalos nuevos de incertidumbre.



Evaluación histórica LSTM de la serie total, conservada del avance.

Plan de trabajo

La tabla actualiza la planificación de cierre y conserva responsables por actividad. Los resultados indicados son entregables previstos; la verificación técnica se describe después de la tabla.

Fecha	Responsable	Actividad	Resultado
24 oct.	Ihan	Organizar las fuentes y reproducir los agregados por mes, mercado, región y frontera.	Datos y auditoría
24 oct.	Diego	Completar filtros, niveles de detalle y el enlace entre serie y vías.	Interfaz completa
24 oct.	Milton	Revisar la paleta, el bosquejo y el contenido del avance.	Diseño de referencia
24 oct.	Ihan	Contrastar las métricas con la exportación del Laboratorio 1.	Resultados trazables
24 oct.	Diego	Integrar las ocho vistas y ejecutar las pruebas de interacción.	Aplicación verificada
24 oct.	Ihan y Diego	Actualizar el documento de diseño y exportar el PDF.	Informe final
25 oct.	Milton	Revisar etiquetas y limitaciones en la versión completa.	Revisión de contenido
25 oct.	Ihan	Comprobar la ejecución desde los archivos originales.	Reproducción del flujo
25 oct.	Diego	Probar la navegación y los filtros antes de enviar.	Revisión funcional
25 oct.	Todos	Verificar PDF y enlace del repositorio y realizar la entrega.	Entrega final

Verificación de la versión final

Se ejecutaron once pruebas automatizadas: continuidad y conservación de totales, agregaciones y cobertura parcial, referencia estacional, selección válida y fuera de filtro, procedencia de métricas, ocho vistas y tres modelos simples, escalas y filtros, consulta sin datos, selección de vistas y modelos, cambio de mes y consulta de mercados y LSTM. Todas pasaron. Además, en el navegador se seleccionó diciembre de 2014 en la serie y se comprobó el cambio del selector y del desglose por vía.

La versión final cumple las ocho visualizaciones, la selección de vistas, el enlace serie-vías, los niveles de detalle y la comparación de modelos existentes. Los resultados describen registros académicos y su evaluación histórica. Se recomienda revisar la fuente y comparar meses equivalentes antes de usar variaciones para decisiones de gestión; el tablero no demuestra causas ni garantiza predicciones futuras.

Referencias

Equipo del proyecto. Base_Migracion_2009-2026jun.xlsx, hojas Datos y Notas. Copia original conservada en data/raw. Las cantidades filtradas reproducen la serie del avance.

Equipo del proyecto. Laboratorio 1 Series de Tiempo. Exportación comparacion_modelos.csv y cuaderno laboratorio-1-series-tiempo.ipynb. El archivo data/raw/modelos_lab1.csv conserva las métricas usadas en la entrega final.

Equipo del proyecto. Laboratorio 2. Predicciones y métricas LSTM conservadas en el avance del Laboratorio 10. Los informes de avance permanecen como referencia histórica.

Menene. CC3084 Data Science 2026. Estructura de proyectos del curso. https://github.com/menene/cc3084-2026-02-40

Streamlit. st.plotly_chart y AppTest. https://docs.streamlit.io/develop/api-reference/charts/st.plotly_chart y https://docs.streamlit.io/develop/api-reference/app-testing/st.testing.v1.apptest